Caracterización de la cancelación del servicio en clientes de telecomunicaciones: análisis descriptivo del dataset Telco Customer Churn

Integrantes

Grupo 1

Jeremy Iván Pedraza Hernández

Docente

Andrés Felipe Callejas Jaramillo

Proyecto Integrado III - Analítica de Datos

PREICA2602B020038

Ingeniería de Software y Datos

Facultad de Ingeniería y Ciencias Agropecuarias

Institución Universitaria Digital de Antioquia.

2026

INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

Contenido

Actualizar este campo en Word con F9

Lista de tablas

Actualizar este campo en Word con F9

1. Introducción

El sector de las telecomunicaciones opera en un mercado altamente competitivo en el que la retención de clientes es un factor determinante de la sostenibilidad del negocio. La cancelación del servicio, conocida como rotación o churn, representa la pérdida de clientes activos y, con ella, de los ingresos recurrentes asociados. En este contexto, el análisis descriptivo de los datos de clientes permite caracterizar los perfiles que concentran la cancelación y orientar decisiones comerciales informadas.

El presente documento corresponde a la primera etapa del proyecto integrador y utiliza el conjunto de datos público «scikit-learn/churn-prediction» (Telco Customer Churn), disponible en Hugging Face. El dataset reúne 7043 registros de clientes y 21 variables originales que describen su perfil, los servicios contratados y su facturación, además de la variable objetivo churn.

El propósito de esta etapa es reconocer el dataset, evaluar su calidad, preparar las variables y documentar la necesidad analítica que guiará las etapas siguientes. El documento se organiza en el planteamiento de la necesidad, la justificación, los objetivos, el marco teórico inicial, los materiales y métodos, los resultados del reconocimiento del dataset, las conclusiones y las recomendaciones.

Este trabajo constituye la primera de tres etapas del proyecto integrador; las etapas posteriores abordarán el análisis exploratorio en profundidad y el modelado orientado a la predicción de la cancelación.

2. Planteamiento de la necesidad

2.1 Contexto y beneficiario

El beneficiario de este análisis es el área comercial y de retención de clientes de una compañía de telecomunicaciones. Esta área enfrenta permanentemente la decisión de dónde concentrar sus esfuerzos de retención, ya que no todos los clientes presentan el mismo riesgo de cancelación. Disponer de una caracterización de los clientes que cancelan frente a los que permanecen apoya la asignación eficiente de recursos de retención.

2.2 Necesidad de información

Se requiere caracterizar qué perfiles de clientes concentran la cancelación del servicio, considerando variables contractuales (contract, paperless_billing, payment_method), de servicios (internet_service, online_security, tech_support,

streaming_tv, entre otras) y de facturación (monthly_charges, total_charges, tenure). Se declara de forma explícita que esta es una necesidad propuesta con fines académicos y no un problema observado y comprobado en una organización real.

2.3 Pregunta de análisis

¿Qué características contractuales, de servicio y de facturación distinguen a los clientes que cancelan el servicio frente a los que permanecen? Esta pregunta puede responderse con las variables disponibles en el dataset: la variable objetivo churn, las variables contractuales contract, paperless_billing y payment_method, las variables de servicios internet_service, online_security, online_backup, device_protection, tech_support, streaming_tv y streaming_movies, y las variables de facturación tenure, monthly_charges y total_charges.

2.4 Escenario

El escenario es hipotético. El dataset es un conjunto de referencia público y no corresponde a una empresa colombiana ni a una organización específica; se emplea como caso de estudio para ejercitar el proceso de analítica descriptiva dentro de la asignatura.

3. Justificación

El costo de adquirir un cliente nuevo suele ser considerablemente mayor que el de retener a un cliente existente, por lo que anticipar y comprender la cancelación tiene un impacto económico directo. Un análisis descriptivo sólido es el punto de partida para priorizar acciones de retención y para fundamentar modelos predictivos posteriores.

El dataset seleccionado es pertinente porque combina variables contractuales, de servicios contratados y de facturación junto con la variable objetivo churn, lo que permite abordar la necesidad planteada sin requerir fuentes adicionales. Académicamente, el ejercicio consolida las competencias de carga, exploración, preparación y documentación de datos propias de la asignatura Proyecto Integrado III - Analítica de Datos.

4. Objetivos

4.1 Objetivo general

Caracterizar, mediante análisis descriptivo, las diferencias contractuales, de servicio y de facturación entre los clientes que cancelan el servicio y los que permanecen, a partir del dataset Telco Customer Churn.

4.2 Objetivos específicos

- Obtener y cargar el dataset desde Hugging Face en un DataFrame de pandas.
- Reconocer la estructura y la calidad del dataset (dimensiones, tipos de datos, valores nulos y duplicados).
- Preparar y documentar las variables mediante transformaciones de limpieza, tipado, derivación y segmentación.
- Caracterizar y comparar de forma descriptiva los grupos de permanencia y cancelación según las variables disponibles.

5. Marco teórico inicial

5.1 Analítica descriptiva

La analítica descriptiva busca resumir y describir las características principales de un conjunto de datos para responder qué ha ocurrido, mediante medidas de resumen, frecuencias y distribuciones (Provost & Fawcett, 2013). Se diferencia de la analítica predictiva, que estima resultados futuros, y de la prescriptiva, que recomienda acciones; la descriptiva constituye el fundamento sobre el que se construyen ambas.

5.2 Rotación de clientes (churn)

La rotación de clientes o churn es la pérdida de clientes durante un periodo determinado. La tasa de cancelación es un indicador clave de la gestión comercial, pues afecta directamente los ingresos recurrentes y el valor de vida del cliente. Su análisis permite identificar factores asociados al abandono y diseñar estrategias de retención (Verbeke et al., 2012).

5.3 Calidad de datos

La calidad de los datos condiciona la validez de cualquier conclusión. Aspectos como los valores nulos, el tipado correcto de las variables y la presencia de

registros duplicados deben evaluarse y tratarse antes del análisis, ya que de lo contrario pueden sesgar los resultados (Han, Kamber & Pei, 2011).

5.4 Herramientas

Hugging Face Datasets es un repositorio y una librería que facilita el acceso reproducible a conjuntos de datos públicos (Lhoest et al., 2021). pandas es la librería estándar de Python para la manipulación de datos tabulares, con estructuras como el DataFrame que permiten cargar, transformar y resumir información de manera eficiente (McKinney, 2010).

6. Materiales y métodos (metodología de la etapa 1)

6.1 Ficha del dataset

Campo	Valor
Nombre	Telco Customer Churn
Identificador del repositorio	scikit-learn/churn-prediction
Enlace directo	https://huggingface.co/datasets/scikit-learn/churn-prediction
Propietario	scikit-learn (organización en Hugging Face)
Licencia y condiciones de uso	Según ficha del dataset en Hugging Face
Modalidad	Tabular (CSV)
Tamaño	7043 filas x 21 columnas (crudo)
Split utilizado	train
Revisión	No fijada (última disponible)
Fecha de consulta	2026-10-24T16:02:41.145849+00:00
Naturaleza de los datos	De referencia pública; según ficha

Tabla 1. Ficha del dataset. *Fuente: elaboración propia a partir de la ficha del dataset en Hugging Face.*

6.2 Justificación de la selección

Frente a alternativas como datasets de clasificación genérica (por ejemplo Iris, usado en la EA1) o datasets sin variable objetivo de negocio, Telco Customer Churn se seleccionó porque plantea un problema real de negocio, incluye una variable objetivo (churn) y combina atributos contractuales, de servicios y de facturación, lo que lo hace idóneo para la necesidad planteada.

6.3 Unidad de análisis

La unidad de análisis es el cliente: cada fila del DataFrame representa un cliente del servicio de telecomunicaciones, identificado por customer_id, con sus atributos de perfil, servicios contratados, facturación y su estado de cancelación (churn).

6.4 Diccionario inicial de variables

Variable	Significado	Tipo	Categorías / unidad
customer_id	Identificador único del cliente.	object	7043 valores distintos (p. ej. identificador)
gender	Género del cliente.	object	Categorías: Female, Male
senior_citizen	Indica si el cliente es adulto mayor (1) o no (0).	int64	Numérica (mín=0, máx=1)
partner	Indica si el cliente tiene pareja.	object	Categorías: Yes, No
dependents	Indica si el cliente tiene personas a cargo.	object	Categorías: No, Yes
tenure	Antigüedad del cliente en meses con la compañía.	int64	Numérica (mín=0, máx=72)
phone_service	Indica si el cliente tiene servicio telefónico.	object	Categorías: No, Yes
multiple_lines	Indica si el cliente tiene múltiples líneas telefónicas.	object	Categorías: No phone service, No, Yes
internet_service	Tipo de servicio de internet contratado.	object	Categorías: DSL, Fiber optic, No
online_security	Indica si el cliente tiene seguridad en línea contratada.	object	Categorías: No, Yes, No internet service
online_backup	Indica si el cliente tiene copia de seguridad en línea.	object	Categorías: Yes, No, No internet service
device_protection	Indica si el cliente tiene protección de dispositivos.	object	Categorías: No, Yes, No internet service

tech_support	Indica si el cliente tiene soporte técnico contratado.	object	Categorías: No, Yes, No internet service
streaming_tv	Indica si el cliente tiene servicio de televisión por streaming.	object	Categorías: No, Yes, No internet service
streaming_movies	Indica si el cliente tiene servicio de películas por streaming.	object	Categorías: No, Yes, No internet service
contract	Tipo de contrato del cliente (mensual, anual o bianual).	object	Categorías: Month-to-month, One year, Two year
paperless_billing	Indica si el cliente usa facturación electrónica.	object	Categorías: Yes, No
payment_method	Método de pago utilizado por el cliente.	object	Categorías: Electronic check, Mailed check, Bank transfer (automatic), Credit card (automatic)
monthly_charges	Cargo mensual facturado al cliente (unidad monetaria).	float64	Numérica (mín=18.25, máx=118.75)
total_charges	Cargo total acumulado facturado al cliente (unidad monetaria).	float64	Numérica (mín=0.0, máx=8684.8)
churn	Variable objetivo: indica si el cliente canceló el servicio.	object	Categorías: No, Yes
cargo_promedio_mensual	Variable derivada: total_charges / tenure, cargo promedio por mes de antigüedad (unidad monetaria).	float64	Numérica (mín=0.0, máx=121.4)
segmento_anti	Variable derivada:	object	Categorías: 0-12,

guedad	segmentación de tenure en rangos (0-12, 13-24, 25-48, 49+ meses).		25-48, 13-24, 49+

Tabla 2. Diccionario inicial de variables. *Fuente: elaboración propia a partir del DataFrame transformado.*

6.5 Herramientas y entorno

El desarrollo se realizó en Python con Jupyter Notebook, control de versiones con Git y alojamiento en GitHub. Las librerías principales y sus versiones mínimas, según requirements.txt, se presentan en la Tabla 3.

Librería / herramienta	Versión
pandas	>=2.0.0
datasets	>=2.14.0
pyarrow	>=12.0.0
huggingface_hub	>=0.16.0
numpy	>=1.24.0
matplotlib	>=3.7.0
jupyter	>=1.0.0
ipykernel	>=6.25.0

Tabla 3. Herramientas y versiones del entorno. *Fuente: elaboración propia a partir de requirements.txt.*

6.6 Procedimiento ejecutado

El procedimiento de la etapa 1 comprendió: (1) la carga del dataset mediante la clase HFDatasetLoader, que se conecta a Hugging Face y devuelve un DataFrame; (2) la exploración descriptiva inicial; (3) cinco transformaciones de preparación; y (4) la generación automática del resumen con la clase DatasetSummarizer.

- T1 - Renombrado de columnas a snake_case para estandarizar su notación.
- T2 - Conversión de total_charges de texto a numérico con pd.to_numeric(errors='coerce'), dado que contenía cadenas vacías.
- T3 - Tratamiento de los nulos resultantes de total_charges, imputados con 0.0 por corresponder a clientes con tenure = 0.
- T4 - Creación de la variable derivada cargo_promedio_mensual = total_charges / tenure, protegiendo la división por cero.
- T5 - Segmentación de la antigüedad (tenure) en rangos mediante pd.cut, generando segmento_antiguedad.

Archivos generados (rutas relativas a la raíz del repositorio): AE2/resultados/churn_crudo.csv, AE2/resultados/churn_transformado.csv y AE2/resultados/resumen_dataframe.txt. El notebook de referencia es AE2/notebooks/ae2_exploracion_descriptiva.ipynb.

6.7 Alcance y limitaciones

El alcance de esta etapa es descriptivo. La unidad de análisis es el cliente y la cobertura corresponde a los registros del split train. Los datos no incluyen marca temporal, por lo que no permiten establecer tendencias en el tiempo. De forma explícita, los datos no permiten inferir causalidad, ni extrapolar los resultados a otro mercado o país, ni afirmar hallazgos predictivos en esta etapa.

6.8 Diseño inicial del análisis

Las variables relevantes para la pregunta son churn (objetivo), contract, payment_method, internet_service, tenure, monthly_charges y total_charges. Los pasos previstos de la etapa descriptiva son: describir la distribución de la variable objetivo, comparar las frecuencias de las variables contractuales y de servicio entre clientes que cancelan y permanecen, y resumir las variables de facturación por grupo. Cada paso se relaciona directamente con la pregunta de análisis al contrastar los dos grupos de interés.

7. Resultados - reconocimiento del dataset

7.1 Dimensiones y estructura

El dataset crudo contiene 7043 filas y 21 columnas. Tras la preparación, el DataFrame transformado conserva 7043 filas y amplía a 23 columnas por la incorporación de las variables derivadas cargo_promedio_mensual y segmento_antiguedad. No se eliminaron registros: no se detectaron filas duplicadas.

7.2 Tipos de datos y valores nulos

La variable total_charges venía originalmente como texto con cadenas vacías; al convertirla a numérica se identificaron 11 valores nulos (0.16% del total), todos correspondientes a clientes con tenure = 0, que fueron imputados con 0.0. Tras la preparación, el DataFrame transformado no presenta valores nulos. La Tabla 4 resume el tipo de dato y los nulos por columna en el DataFrame transformado.

Variable	Tipo	Nulos	% nulos
customer_id	object	0	0.00%

gender	object	0	0.00%
senior_citizen	int64	0	0.00%
partner	object	0	0.00%
dependents	object	0	0.00%
tenure	int64	0	0.00%
phone_service	object	0	0.00%
multiple_lines	object	0	0.00%
internet_service	object	0	0.00%
online_security	object	0	0.00%
online_backup	object	0	0.00%
device_protection	object	0	0.00%
tech_support	object	0	0.00%
streaming_tv	object	0	0.00%
streaming_movies	object	0	0.00%
contract	object	0	0.00%
paperless_billing	object	0	0.00%
payment_method	object	0	0.00%
monthly_charges	float64	0	0.00%
total_charges	float64	0	0.00%
churn	object	0	0.00%
cargo_promedio_mensual	float64	0	0.00%
segmento_antiguedad	object	0	0.00%

Tabla 4. Tipos de datos y valores nulos por columna (DataFrame transformado). *Fuente: elaboración propia a partir de AE2/resultados/churn_transformado.csv.*

7.3 Distribución de las variables clave

La variable objetivo churn presenta 5174 clientes que permanecen (No) y 1869 que cancelan (Yes), es decir una tasa de cancelación del 26.54%. Las Tablas 5 a 7 presentan las frecuencias de las variables contractuales y de servicio, y la Tabla 8 las estadísticas descriptivas de las variables de facturación.

contract	Frecuencia
Month-to-month	3875
Two year	1695
One year	1473

Tabla 5. Frecuencia por tipo de contrato. *Fuente: elaboración propia a partir de AE2/resultados/churn_transformado.csv.*

internet_service	Frecuencia
Fiber optic	3096
DSL	2421
No	1526

Tabla 6. Frecuencia por tipo de servicio de internet. *Fuente: elaboración propia a partir de AE2/resultados/churn_transformado.csv.*

payment_method	Frecuencia
Electronic check	2365
Mailed check	1612
Bank transfer (automatic)	1544
Credit card (automatic)	1522

Tabla 7. Frecuencia por método de pago. *Fuente: elaboración propia a partir de AE2/resultados/churn_transformado.csv.*

Estadístico	tenure	monthly_charges	total_charges
count	7043.00	7043.00	7043.00
mean	32.37	64.76	2279.73
std	24.56	30.09	2266.79
min	0.00	18.25	0.00
25%	9.00	35.50	398.55
50%	29.00	70.35	1394.55
75%	55.00	89.85	3786.60
max	72.00	118.75	8684.80

Tabla 8. Estadísticas descriptivas de las variables de facturación. *Fuente: elaboración propia a partir de AE2/resultados/churn_transformado.csv.*

7.4 Evidencia del resumen automático

El resumen se genera automáticamente con la clase DatasetSummarizer y se guarda en la ruta relativa AE2/resultados/resumen_dataframe.txt, en codificación UTF-8, regenerándose en cada ejecución del notebook. A continuación se transcribe su contenido íntegro.

```
============================================================
```

INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

RESUMEN DEL DATASET

```
============================================================
1. IDENTIFICACION
------------------------------------------------------------
   dataset_id      : scikit-learn/churn-prediction
   split           : train
   configuracion   : None
   revision        : None
   fecha_consulta  : 2026-10-24T16:02:41.145849+00:00
   es_muestra      : False


2. DIMENSIONES
------------------------------------------------------------
   filas    : 7043
   columnas : 23


3. COLUMNAS Y TIPOS
------------------------------------------------------------
   customer_id                   object
   gender                        object
   senior_citizen                int64
   partner                       object
   dependents                    object
   tenure                        int64
   phone_service                 object
   multiple_lines                object
   internet_service              object
   online_security               object
   online_backup                 object
   device_protection             object
   tech_support                  object
   streaming_tv                  object
   streaming_movies              object
   contract                      object
   paperless_billing             object
   payment_method                object
   monthly_charges               float64
   total_charges                 float64
   churn                         object
   cargo_promedio_mensual        float64
   segmento_antiguedad           category


4. VALORES NULOS POR COLUMNA
------------------------------------------------------------
   customer_id                          0  ( 0.00%)
   gender                               0  ( 0.00%)
   senior_citizen                       0  ( 0.00%)
   partner                              0  ( 0.00%)
   dependents                           0  ( 0.00%)
   tenure                               0  ( 0.00%)
   phone_service                        0  ( 0.00%)
   multiple_lines                       0  ( 0.00%)
   internet_service                     0  ( 0.00%)
   online_security                      0  ( 0.00%)
   online_backup                        0  ( 0.00%)
   device_protection                    0  ( 0.00%)
   tech_support                         0  ( 0.00%)
   streaming_tv                         0  ( 0.00%)
   streaming_movies                     0  ( 0.00%)
   contract                             0  ( 0.00%)
   paperless_billing                    0  ( 0.00%)
```

```
   payment_method                 0  ( 0.00%)
   monthly_charges                0  ( 0.00%)
   total_charges                  0  ( 0.00%)
   churn                          0  ( 0.00%)
   cargo_promedio_mensual         0  ( 0.00%)
   segmento_antiguedad            0  ( 0.00%)


5. FILAS DUPLICADAS
------------------------------------------------------------
   duplicados : 0


6. ESTADISTICAS DESCRIPTIVAS (NUMERICAS)
------------------------------------------------------------
       senior_citizen       tenure  monthly_charges  total_charges  cargo_promedio_mensual
count     7043.000000  7043.000000      7043.000000    7043.000000             7043.000000
mean         0.162147    32.371149        64.761692    2279.734304               64.698184
std          0.368612    24.559481        30.090047    2266.794470               30.270690
min          0.000000     0.000000        18.250000       0.000000                0.000000
25%          0.000000     9.000000        35.500000     398.550000               35.650000
50%          0.000000    29.000000        70.350000    1394.550000               70.300000
75%          0.000000    55.000000        89.850000    3786.600000               90.170000
max          1.000000    72.000000       118.750000    8684.800000              121.400000


7. FRECUENCIAS (CATEGORICAS, TOP 5)
------------------------------------------------------------
   [customer_id]
      3186-AJIEK                   1
      7590-VHVEG                   1
      5575-GNVDE                   1
      8775-CEBBJ                   1
      2823-LKABH                   1
   [gender]
      Male                         3555
      Female                       3488
   [partner]
      No                           3641
      Yes                          3402
   [dependents]
      No                           4933
      Yes                          2110
   [phone_service]
      Yes                          6361
      No                           682
   [multiple_lines]
      No                           3390
      Yes                          2971
      No phone service             682
   [internet_service]
      Fiber optic                  3096
      DSL                          2421
      No                           1526
   [online_security]
      No                           3498
      Yes                          2019
      No internet service          1526
   [online_backup]
      No                           3088
      Yes                          2429
      No internet service          1526
   [device_protection]
      No                           3095
```

```
   Yes                          2422
   No internet service          1526
[tech_support]
   No                           3473
   Yes                          2044
   No internet service          1526
[streaming_tv]
   No                           2810
   Yes                          2707
   No internet service          1526
[streaming_movies]
   No                           2785
   Yes                          2732
   No internet service          1526
[contract]
   Month-to-month               3875
   Two year                     1695
   One year                     1473
[paperless_billing]
   Yes                          4171
   No                           2872
[payment_method]
   Electronic check             2365
   Mailed check                 1612
   Bank transfer (automatic)    1544
   Credit card (automatic)      1522
[churn]
   No                           5174
   Yes                          1869
[segmento_antiguedad]
   49+                          2239
   0-12                         2186
   25-48                        1594
   13-24                        1024
```

7.5 Relación con la necesidad

Las variables churn, contract, payment_method e internet_service, junto con tenure, monthly_charges y total_charges, respaldan directamente la pregunta de análisis, pues permiten contrastar el comportamiento contractual, de servicio y de facturación entre los clientes que cancelan y los que permanecen. Esta correspondencia confirma la coherencia entre la necesidad planteada y los datos disponibles.

8. Conclusiones

- El dataset Telco Customer Churn es viable para la necesidad planteada: sus 23 variables cubren las dimensiones contractual, de servicio y de facturación requeridas por la pregunta de análisis.
- La calidad de los datos es adecuada tras la preparación: el único problema relevante fueron los 11 valores nulos de total_charges, identificados y tratados; no se hallaron duplicados.

- Existe coherencia entre la pregunta de análisis y las variables disponibles, en particular la variable objetivo churn y las variables contractuales, de servicio y de facturación.
- La etapa deja preparado el terreno para el análisis exploratorio y el modelado de las etapas siguientes, con un DataFrame limpio, tipado y documentado, y un resumen reproducible.

9. Recomendaciones

- Realizar en la etapa 2 un análisis bivariado de churn frente a contract, tenure y monthly_charges para cuantificar las diferencias entre grupos.
- Incorporar visualizaciones (histogramas y gráficos de barras) que faciliten la comparación de los perfiles de cancelación.
- Evaluar la codificación de variables categóricas y el escalado de variables numéricas de cara al modelado predictivo de la etapa 3.
- Documentar y fijar la revisión del dataset para garantizar la reproducibilidad exacta en futuras ejecuciones.

10. Referencias

Han, J., Kamber, M., & Pei, J. (2011). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.

Lhoest, Q., et al. (2021). Datasets: A community library for natural language processing. En Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (pp. 175-184). Association for Computational Linguistics.

McKinney, W. (2010). Data structures for statistical computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 56-61).

Provost, F., & Fawcett, T. (2013). Data science for business. O'Reilly Media.

Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B. (2012). New insights into churn prediction in the telecommunication sector. European Journal of Operational Research, 218(1), 211-229.

scikit-learn. (s. f.). Churn prediction dataset [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/scikit-learn/churn-prediction

pandas development team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/

Hugging Face. (s. f.). Datasets documentation. https://huggingface.co/docs/datasets

Pedraza Hernández, J. I. (2026). Repositorio del proyecto PREICA2602B020038 - Analítica de Datos [Repositorio]. GitHub. https://github.com/Jeremy-Pedraza/PREICA2602B020038-Analisis-de-Datos