Transformacion y enriquecimiento del dataset Telco Customer Churn para responder las preguntas de negocio sobre la cancelacion del servicio

Documento de avance - Etapa 2 (AE3)

Integrantes

Grupo 1

Jeremy Ivan Pedraza Hernandez

Docente

Andres Felipe Callejas Jaramillo

Proyecto Integrado III - Analitica de Datos

PREICA2602B020038

Ingenieria de Software y Datos

Facultad de Ingenieria y Ciencias Agropecuarias

Institucion Universitaria Digital de Antioquia.

2026

IU Digital de Antioquia
INSTITUCIÓN UNIVERSITARIA DIGITAL DE ANTIOQUIA

Contenido

1. Introduccion 3
2. Necesidad y preguntas de negocio 3
   2.1 Necesidad analitica (retomada de AE2) 3
   2.2 Preguntas de negocio y variables 3
3. Metodologia 4
   3.1 Flujo general 4
   3.2 Transformaciones y reglas de calidad 4
   3.3 Enriquecimiento 5
   3.4 Diccionario de datos actualizado 6
   3.5 Herramientas y entorno 8
4. Resultados y discusion 9
   4.1 P1 - Cancelacion por tipo de contrato 9
   4.2 P2 - Cancelacion por antiguedad 9
   4.3 P3 - Cancelacion por metodo de pago y servicio de internet 9
   4.4 P4 - Facturacion comparada entre grupos 10
   4.5 P5 - Cancelacion por numero de servicios adicionales 10
   4.6 Evidencia del resumen automatico 11
   4.7 Limitaciones de los resultados 14
5. Conclusiones del avance 14
6. Referencias 15

1. Introduccion

Este documento corresponde a la segunda etapa (AE3) del proyecto integrador y da continuidad al avance presentado en AE2, conservando el mismo proyecto, dataset y repositorio. Mientras AE2 cubrio la carga, la exploracion y la preparacion inicial del conjunto de datos, AE3 se centra en transformar y enriquecer los datos para responder de forma descriptiva las preguntas de negocio derivadas de la necesidad analitica.

El conjunto de datos es «scikit-learn/churn-prediction» (Telco Customer Churn), disponible en Hugging Face, con 7043 registros de clientes y 21 variables originales. Cada fila es un cliente y la variable objetivo es la cancelacion del servicio (churn). El documento registra que se transformo y por que, que variables se incorporaron, y presenta una tabla de resultados por cada pregunta de negocio con su interpretacion y limitaciones.

2. Necesidad y preguntas de negocio

2.1 Necesidad analitica (retomada de AE2)

El beneficiario es el area comercial y de retencion de una compania de telecomunicaciones, que necesita caracterizar que perfiles de clientes concentran la cancelacion del servicio para asignar de forma eficiente sus esfuerzos de retencion. La necesidad se mantiene sin cambios respecto de AE2; en AE3 se operacionaliza en preguntas concretas respondibles con los datos.

2.2 Preguntas de negocio y variables

La pregunta general de AE2 -que caracteristicas distinguen a los clientes que cancelan frente a los que permanecen se descompone en cinco preguntas operativas. La Tabla 1 relaciona cada pregunta con las variables necesarias y el resultado esperado.

#	Pregunta de negocio	Variables necesarias	Resultado esperado
P1	Que tipo de contrato concentra mayor tasa de cancelacion?	contract, churn	Tasa de churn por tipo de contrato
P2	Como varia la cancelacion segun la	tenure -> segmento_antiguedad, churn	Tasa de churn por segmento

	antiguedad del cliente?		
P3	Que metodo de pago y servicio de internet se asocian con mas churn?	payment_method, internet_service, churn	Tasa de churn por cada uno
P4	Como difieren los cargos entre quienes cancelan y permanecen?	monthly_charges, total_charges, cargo_promedio_mensual, tenure, churn	Promedios de facturacion por grupo
P5	Influye la cantidad de servicios adicionales en la cancelacion?	add-ons -> num_servicios_adicionales, churn	Tasa de churn por numero de servicios

Tabla 1. Preguntas de negocio, variables y resultado esperado. *Fuente: elaboracion propia a partir de la necesidad definida en AE2.*

Limitacion de alcance: el dataset no incluye marca temporal ni datos de costos, por lo que las respuestas son descriptivas y no permiten analisis de tendencia, de rentabilidad ni inferencia causal.

3. Metodologia

3.1 Flujo general

El procedimiento sigue el flujo: dataset de AE2 -> transformacion y validacion -> enriquecimiento -> respuestas a las preguntas -> tablas de resultados y archivos exportados. Todo se ejecuta por codigo en el notebook EA3/notebooks/ea3_transformacion_enriquecimiento.ipynb con rutas relativas, conservando una version sin modificar del dataset para comparar los cambios.

3.2 Transformaciones y reglas de calidad

Se aplicaron las siguientes transformaciones de preparacion, cada una validada con el conteo de registros afectados:

- T1 - Renombrado de columnas a snake_case para estandarizar la notacion (afecta a las 21 columnas, sin perdida de datos).

- T2 - Conversion de total_charges de texto a numerico con pd.to_numeric(errors='coerce'), dado que contenia cadenas vacias; la conversion revelo 11 valores nulos (0.16%).
- T3 - Tratamiento de los nulos de total_charges: todos corresponden a clientes con tenure = 0, por lo que se imputan con 0.0 (valor coherente para un cliente nuevo). No se elimino ningun registro.

Reglas de calidad verificadas: no se hallaron filas duplicadas (0), por lo que no se eliminaron registros; tras el tratamiento, el DataFrame no presenta valores nulos. Ningun dato se elimino ni se imputo sin justificar el criterio.

3.3 Enriquecimiento

Se incorporaron variables derivadas a partir de las variables existentes, sin usar fuentes externas. La Tabla 2 resume su formula, significado y utilidad.

Variable	Formula / regla	Significado	Utilidad
cargo_promedio_mensual	total_charges / tenure (0 si tenure=0)	Cargo medio por mes de antiguedad	P4
segmento_antiguedad	pd.cut(tenure): 0-12, 13-24, 25-48, 49+	Rango de antiguedad del cliente	P2
churn_flag	1 si churn=='Yes', si no 0	Objetivo numerico	Tasa de churn en todas las preguntas
num_servicios_adicionales	conteo de 6 add-ons == 'Yes'	Cantidad de servicios extra contratados	P5
grupo_cargo_mensual	pd.cut(monthly_charges): Bajo/Medio/Alto	Nivel de gasto mensual	Perfil de facturacion

Tabla 2. Variables incorporadas en el enriquecimiento (AE3). *Fuente: elaboracion propia.*

El enriquecimiento se realizo con los datos existentes; no se combinaron otras tablas, por lo que no hubo riesgo de multiplicar registros por una union.

3.4 Diccionario de datos actualizado

La Tabla 3 presenta el diccionario del DataFrame final (26 variables), que incorpora las 3 variables nuevas de AE3 (churn_flag, num_servicios_adicionales y grupo_cargo_mensual) ademas de las derivadas en AE2.

Variable	Significado	Tipo	Categorias / unidad
customer_id	Identificador unico del cliente.	object	7043 valores distintos (p. ej. identificador)
gender	Genero del cliente.	object	Categorias: Female, Male
senior_citizen	Indica si el cliente es adulto mayor (1) o no (0).	int64	Numerica (min=0, max=1)
partner	Indica si el cliente tiene pareja.	object	Categorias: Yes, No
dependents	Indica si el cliente tiene personas a cargo.	object	Categorias: No, Yes
tenure	Antiguedad del cliente en meses con la compania.	int64	Numerica (min=0, max=72)
phone_service	Indica si el cliente tiene servicio telefonico.	object	Categorias: No, Yes
multiple_lines	Indica si el cliente tiene multiples lineas telefonicas.	object	Categorias: No phone service, No, Yes
internet_service	Tipo de servicio de internet contratado.	object	Categorias: DSL, Fiber optic, No
online_security	Indica si el cliente tiene seguridad en linea contratada.	object	Categorias: No, Yes, No internet service
online_backup	Indica si el cliente tiene copia de seguridad en linea.	object	Categorias: Yes, No, No internet service
device_protection	Indica si el cliente tiene proteccion de dispositivos.	object	Categorias: No, Yes, No internet service

tech_support	Indica si el cliente tiene soporte tecnico contratado.	object	Categorias: No, Yes, No internet service
streaming_tv	Indica si el cliente tiene television por streaming.	object	Categorias: No, Yes, No internet service
streaming_movies	Indica si el cliente tiene peliculas por streaming.	object	Categorias: No, Yes, No internet service
contract	Tipo de contrato del cliente (mensual, anual o bianual).	object	Categorias: Month-to-month, One year, Two year
paperless_billing	Indica si el cliente usa facturacion electronica.	object	Categorias: Yes, No
payment_method	Metodo de pago utilizado por el cliente.	object	Categorias: Electronic check, Mailed check, Bank transfer (automatic), Credit card (automatic)
monthly_charges	Cargo mensual facturado al cliente (unidad monetaria).	float64	Numerica (min=18.25, max=118.75)
total_charges	Cargo total acumulado facturado al cliente (unidad monetaria).	float64	Numerica (min=0.0, max=8684.8)
churn	Variable objetivo: indica si el cliente cancelo el servicio.	object	Categorias: No, Yes
cargo_promedio_mensual	Derivada (AE2): total_charges / tenure, cargo promedio por mes de antiguedad (unidad monetaria).	float64	Numerica (min=0.0, max=121.4)

segmento_antiguedad	Derivada (AE2): segmentacion de tenure en rangos (0-12, 13-24, 25-48, 49+ meses).	object	Categorias: 0-12, 25-48, 13-24, 49+
churn_flag	Derivada (AE3): version numerica de churn (1 = cancelo, 0 = permanece); permite calcular la tasa de cancelacion por grupo.	int64	Numerica (min=0, max=1)
num_servicios_adicionales	Derivada (AE3): conteo de servicios adicionales contratados (online_security, online_backup, device_protection, tech_support, streaming_tv, streaming_movies).	int64	Numerica (min=0, max=6)
grupo_cargo_mensual	Derivada (AE3): nivel de gasto mensual segun monthly_charges (Bajo <=35, Medio 35-70, Alto >70).	object	Categorias: Bajo, Medio, Alto

Tabla 3. Diccionario de datos actualizado (DataFrame final). *Fuente: elaboracion propia a partir de EA3/resultados/churn_transformado.csv.*

3.5 Herramientas y entorno

El desarrollo se realizo en Python con Jupyter Notebook, control de versiones con Git y alojamiento en GitHub. La Tabla 4 lista las librerias y versiones minimas segun requirements.txt.

Libreria / herramienta	Version
pandas	>=2.0.0
datasets	>=2.14.0
pyarrow	>=12.0.0
huggingface_hub	>=0.16.0

numpy	>=1.24.0
matplotlib	>=3.7.0
jupyter	>=1.0.0
ipykernel	>=6.25.0

Tabla 4. Herramientas y versiones del entorno. *Fuente: elaboracion propia a partir de requirements.txt.*

4. Resultados y discusion

El DataFrame final conserva 7043 filas y amplia a 26 columnas por las variables derivadas. La tasa de cancelacion global es del 26.54% (1869 clientes cancelan y 5174 permanecen). A continuacion se responde cada pregunta con su tabla e interpretacion. Las tablas coinciden con los archivos .csv exportados por el notebook.

4.1 P1 - Cancelacion por tipo de contrato

contract	clientes	cancelaciones	tasa_churn_%
Month-to-month	3875	1655	42.71
One year	1473	166	11.27
Two year	1695	48	2.83

Tabla 5. Tasa de cancelacion por tipo de contrato. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p1_churn_por_contrato.csv.*

El contrato «Month-to-month» concentra la mayor tasa de cancelacion (42.71%), muy por encima de los contratos a termino. Esto indica que la permanencia contractual es un factor protector frente al churn y sugiere incentivar la migracion a contratos anuales.

4.2 P2 - Cancelacion por antiguedad

segmento_antiguedad	clientes	cancelaciones	tasa_churn_%
0-12	2186	1037	47.44
13-24	1024	294	28.71
25-48	1594	325	20.39
49+	2239	213	9.51

Tabla 6. Tasa de cancelacion por segmento de antiguedad. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p2_churn_por_antiguedad.csv.*

La cancelacion es mas alta entre los clientes nuevos (segmento 0-12 meses) y decrece de forma sostenida a medida que aumenta la antiguedad. Los primeros meses de relacion son el periodo de mayor riesgo y el foco natural de las acciones de retencion.

4.3 P3 - Cancelacion por metodo de pago y servicio de internet

payment_method	clientes	cancelaciones	tasa_churn_%
Electronic check	2365	1071	45.29

Mailed check	1612	308	19.11
Bank transfer (automatic)	1544	258	16.71
Credit card (automatic)	1522	232	15.24

Tabla 7. Tasa de cancelacion por metodo de pago. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p3a_churn_por_metodo_pago.csv.*

internet_service	clientes	cancelaciones	tasa_churn_%
Fiber optic	3096	1297	41.89
DSL	2421	459	18.96
No	1526	113	7.4

Tabla 8. Tasa de cancelacion por tipo de servicio de internet. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p3b_churn_por_internet.csv.*

El pago con «Electronic check» y el internet de «Fiber optic» presentan las tasas de cancelacion mas altas. Son segmentos donde conviene revisar la experiencia de pago y la calidad/precio del servicio de internet.

4.4 P4 - Facturacion comparada entre grupos

churn	clientes	tenure_prom	monthly_charges_prom	total_charges_prom	cargo_promedio_mensual_prom
No	5174	37.57	61.27	2549.91	61.18
Yes	1869	17.98	74.44	1531.8	74.43

Tabla 9. Facturacion promedio segun estado de cancelacion. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p4_cargos_por_churn.csv.*

Quienes cancelan tienen menor antiguedad promedio y, al mismo tiempo, un cargo mensual promedio mas alto que quienes permanecen. El patron es consistente con P1-P3: clientes recientes, con mayor gasto mensual y sin ataduras contractuales son los mas propensos a cancelar.

4.5 P5 - Cancelacion por numero de servicios adicionales

num_servicios_adicionales	clientes	cancelaciones	tasa_churn_%
1	966	442	45.76
2	1033	370	35.82
3	1118	306	27.37
4	852	190	22.3
0	2219	475	21.41
5	571	71	12.43
6	284	15	5.28

Tabla 10. Tasa de cancelacion por numero de servicios adicionales. *Fuente: elaboracion propia a partir de EA3/resultados/tabla_p5_churn_por_num_servicios.csv.*

Entre los clientes con servicio de internet, la tasa de cancelacion disminuye a medida que aumenta el numero de servicios adicionales contratados: mas servicios implican mayor vinculacion y menor abandono. El grupo con 0 servicios corresponde en su mayoria a clientes sin internet, por lo que no sigue la misma tendencia y debe interpretarse aparte.

4.6 Evidencia del resumen automatico

El resumen descriptivo del DataFrame final se genera por codigo con la clase DatasetSummarizer y se guarda en EA3/resultados/resumen_dataframe.txt (UTF-8), regenerandose en cada ejecucion. A continuacion se transcribe su contenido.

```
============================================================
RESUMEN DEL DATASET
============================================================
1. IDENTIFICACION
------------------------------------------------------------
   dataset_id      : scikit-learn/churn-prediction
   split           : train
   configuracion   : None
   revision        : None
   fecha_consulta  : 2026-11-09T00:41:31.139492+00:00
   es_muestra      : False


2. DIMENSIONES
------------------------------------------------------------
   filas    : 7043
   columnas : 26


3. COLUMNAS Y TIPOS
------------------------------------------------------------
   customer_id                   object
   gender                        object
   senior_citizen                int64
   partner                       object
   dependents                    object
   tenure                        int64
   phone_service                 object
   multiple_lines                object
   internet_service              object
   online_security               object
   online_backup                 object
   device_protection             object
   tech_support                  object
   streaming_tv                  object
   streaming_movies              object
   contract                      object
   paperless_billing             object
   payment_method                object
   monthly_charges               float64
   total_charges                 float64
   churn                         object
   cargo_promedio_mensual        float64
   segmento_antiguedad           category
   churn_flag                    int64
   num_servicios_adicionales     int64
```

```
   grupo_cargo_mensual            category
```

4. VALORES NULOS POR COLUMNA

```
   customer_id                          0  ( 0.00%)
   gender                               0  ( 0.00%)
   senior_citizen                       0  ( 0.00%)
   partner                              0  ( 0.00%)
   dependents                           0  ( 0.00%)
   tenure                               0  ( 0.00%)
   phone_service                        0  ( 0.00%)
   multiple_lines                       0  ( 0.00%)
   internet_service                     0  ( 0.00%)
   online_security                      0  ( 0.00%)
   online_backup                        0  ( 0.00%)
   device_protection                    0  ( 0.00%)
   tech_support                         0  ( 0.00%)
   streaming_tv                         0  ( 0.00%)
   streaming_movies                     0  ( 0.00%)
   contract                             0  ( 0.00%)
   paperless_billing                    0  ( 0.00%)
   payment_method                       0  ( 0.00%)
   monthly_charges                      0  ( 0.00%)
   total_charges                        0  ( 0.00%)
   churn                                0  ( 0.00%)
   cargo_promedio_mensual               0  ( 0.00%)
   segmento_antiguedad                  0  ( 0.00%)
   churn_flag                           0  ( 0.00%)
   num_servicios_adicionales            0  ( 0.00%)
   grupo_cargo_mensual                  0  ( 0.00%)
```

5. FILAS DUPLICADAS

```
   duplicados : 0
```

6. ESTADISTICAS DESCRIPTIVAS (NUMERICAS)

```
       senior_citizen       tenure  monthly_charges  total_charges  cargo_promedio_mensual   churn_flag
num_servicios_adicionales
count     7043.000000  7043.000000      7043.000000    7043.000000             7043.000000  7043.000000
7043.000000
mean         0.162147    32.371149        64.761692    2279.734304               64.698184     0.265370
2.037910
std          0.368612    24.559481        30.090047    2266.794470               30.270690     0.441561
1.847682
min          0.000000     0.000000        18.250000       0.000000                0.000000     0.000000
0.000000
25%          0.000000     9.000000        35.500000     398.550000               35.650000     0.000000
0.000000
50%          0.000000    29.000000        70.350000    1394.550000               70.300000     0.000000
2.000000
75%          0.000000    55.000000        89.850000    3786.600000               90.170000     1.000000
3.000000
max          1.000000    72.000000       118.750000    8684.800000              121.400000     1.000000
6.000000
```

7. FRECUENCIAS (CATEGORICAS, TOP 5)

```
   [customer_id]
      3186-AJIEK                    1
```

```
   7590-VHVEG                   1
   5575-GNVDE                   1
   8775-CEBBJ                   1
   2823-LKABH                   1
[gender]
   Male                         3555
   Female                       3488
[partner]
   No                           3641
   Yes                          3402
[dependents]
   No                           4933
   Yes                          2110
[phone_service]
   Yes                          6361
   No                           682
[multiple_lines]
   No                           3390
   Yes                          2971
   No phone service             682
[internet_service]
   Fiber optic                  3096
   DSL                          2421
   No                           1526
[online_security]
   No                           3498
   Yes                          2019
   No internet service          1526
[online_backup]
   No                           3088
   Yes                          2429
   No internet service          1526
[device_protection]
   No                           3095
   Yes                          2422
   No internet service          1526
[tech_support]
   No                           3473
   Yes                          2044
   No internet service          1526
[streaming_tv]
   No                           2810
   Yes                          2707
   No internet service          1526
[streaming_movies]
   No                           2785
   Yes                          2732
   No internet service          1526
[contract]
   Month-to-month               3875
   Two year                     1695
   One year                     1473
[paperless_billing]
   Yes                          4171
   No                           2872
[payment_method]
   Electronic check             2365
   Mailed check                 1612
   Bank transfer (automatic)    1544
   Credit card (automatic)      1522
[churn]
   No                           5174
   Yes                          1869
```

```
[segmento_antiguedad]
   49+                          2239
   0-12                         2186
   25-48                        1594
   13-24                        1024
[grupo_cargo_mensual]
   Alto                         3583
   Bajo                         1735
   Medio                        1725
```

4.7 Limitaciones de los resultados

- Las relaciones son asociaciones descriptivas, no relaciones causales.
- Sin datos de costos no puede afirmarse que un segmento sea mas o menos rentable, solo que cancela mas o menos.
- Sin marca temporal no es posible analizar la evolucion de la cancelacion en el tiempo.
- Los resultados corresponden al split train del dataset y no se extrapolan a otro mercado o pais.

5. Conclusiones del avance

- La transformacion y el enriquecimiento dejaron un DataFrame final de 7043 filas y 26 columnas, sin nulos ni duplicados, apto para responder las preguntas de negocio.
- Las cinco preguntas quedaron respondidas con una tabla cada una: el contrato mensual, la baja antiguedad, el pago con cheque electronico, el internet de fibra optica y el menor numero de servicios adicionales se asocian con mayor cancelacion.
- El perfil de mayor riesgo es consistente entre preguntas: cliente reciente, con contrato mensual y cargo mensual alto.
- Los datos transformados y enriquecidos quedan organizados en archivos .csv y un resumen .txt, listos para la representacion grafica de AE4.

Queda sin resolver la cuantificacion de la rentabilidad por segmento (falta de costos) y el analisis temporal de la cancelacion (falta de fecha), aspectos fuera del alcance de esta etapa.

6. Referencias

- Han, J., Kamber, M., & Pei, J. (2011). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.
- Lhoest, Q., et al. (2021). Datasets: A community library for natural language processing. En Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (pp. 175-184). ACL.
- McKinney, W. (2010). Data structures for statistical computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 56-61).
- Provost, F., & Fawcett, T. (2013). Data science for business. O'Reilly Media.
- Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B. (2012). New insights into churn prediction in the telecommunication sector. European Journal of Operational Research, 218(1), 211-229.
- scikit-learn. (s. f.). Churn prediction dataset [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/scikit-learn/churn-prediction
- pandas development team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/
- Hugging Face. (s. f.). Datasets documentation. https://huggingface.co/docs/datasets
- Pedraza Hernandez, J. I. (2026). Repositorio del proyecto PREICA2602B020038 - Analitica de Datos [Repositorio]. GitHub. https://github.com/Jeremy-Pedraza/PREICA2602B020038-Analisis-de-Datos